LOCAL-FIRST INTELLIGENCE VERSION 1.3 RC LOCAL AI EMBEDDED

PERSONAL TASK BOARD (PTB)

Báo Cáo Kiến Trúc Hệ Thống & Toàn Bộ Workflow Vận Hành End-to-End

NGÀY BÁO CÁO	CƠ SỞ DỮ LIỆU CỐT LÕI	DECISION & RERANKER	NGUYÊN TẮC CỐT LÕI
11/10/2026	**Neo4j Single-Store (APOC)**	**Kev-0.8B (Port 8081 / SystemOne)**	**Fail-Fast & Truthful Health**

1. Tổng Quan & Giá Trị Cốt Lõi Dự Án

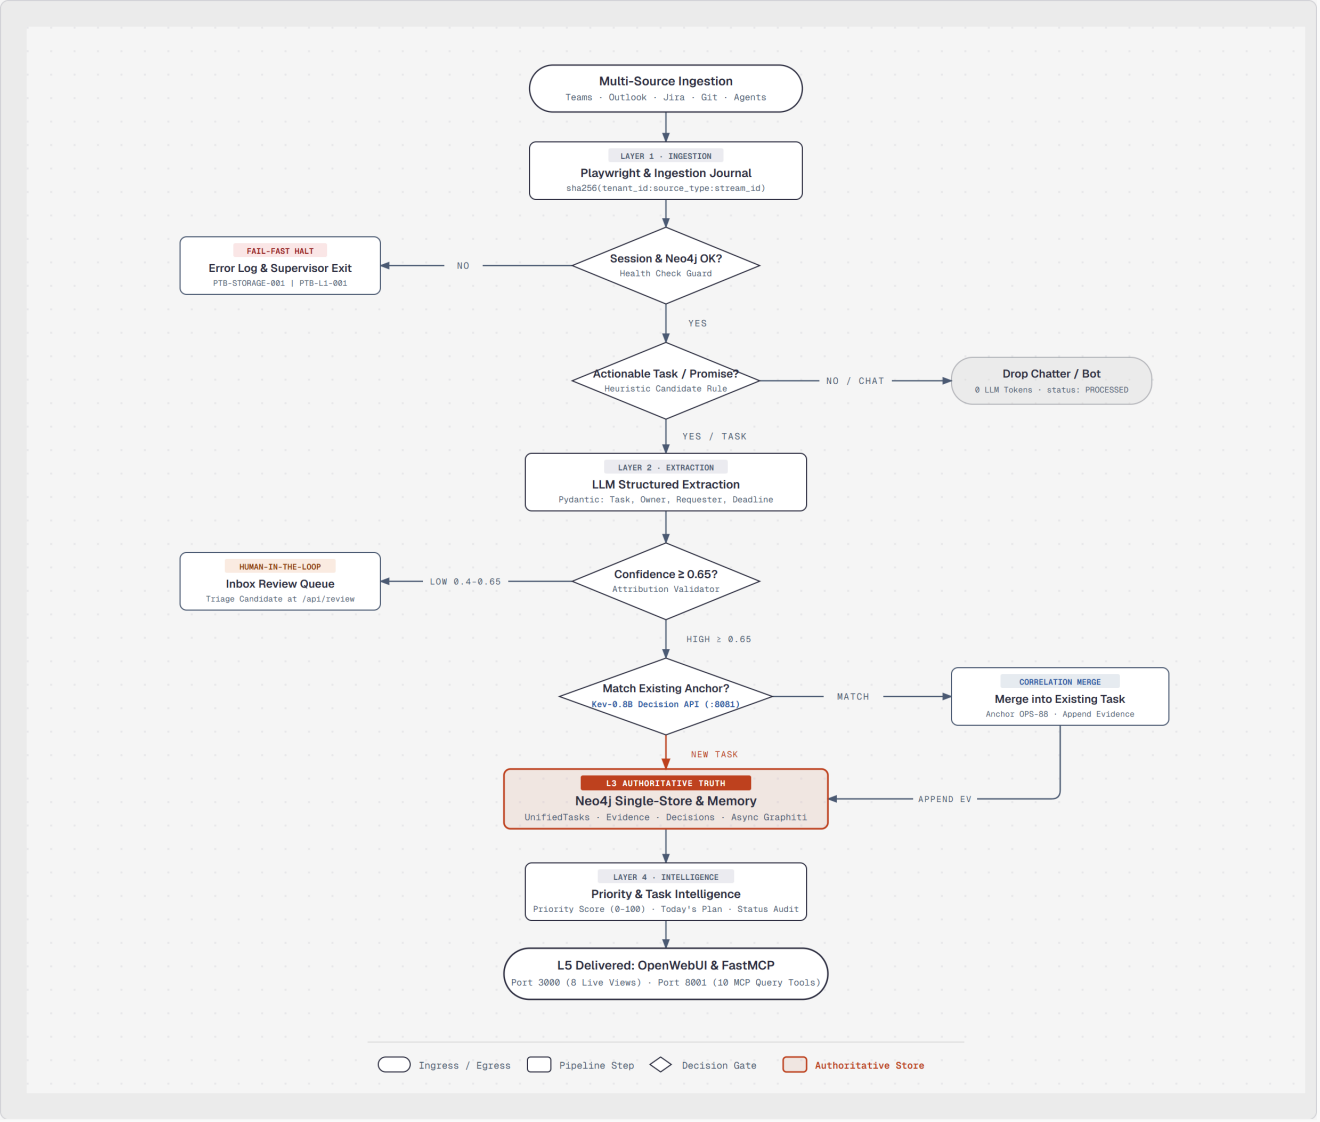
> **Vấn đề thực tế:** Nhiệm vụ và cam kết của một kỹ sư bị phân tán trên nhiều kênh không kết nối được với nhau: ticket chính thức nằm rải rác trên Jira/Shortcut (theo team/epic, không theo cá nhân); lời hứa thực tế nằm trong chat Teams/Outlook ("để em check", "em sẽ deploy..."); và các quyết định kỹ thuật sâu sắc phát sinh liên tục trong phiên làm việc với AI Coding Agents (Cursor, Claude Code, Antigravity, Cline).

Personal Task Board (PTB) giải quyết triệt để sự phân tán này thông qua 5 nguyên tắc thiết kế bất biến:

- **Local-First & Bảo Mật Tuyệt Đối:** Mọi dữ liệu sự kiện, cam kết và đồ thị tri thức được lưu trữ cục bộ trên máy của kỹ sư. Tuyệt đối không đẩy dữ liệu nội bộ lên dịch vụ đám mây công cộng của bên thứ ba.
- **Zero Manual Input (Bắt tự động hoàn toàn):** Lắng nghe network responses qua Playwright và quét session logs cục bộ của IDE, loại bỏ hoàn toàn gánh nặng phải ghi chú hay tạo ticket bằng tay.
- **Neo4j Single-Store làm chân lý duy nhất (Authoritative Store):** Xóa bỏ hoàn toàn việc dùng 2 database riêng biệt. Mọi thực thể từ sự kiện thô (`RawEvent`), con trỏ đồng bộ (`IngestionCheckpoint`), nhiệm vụ hợp nhất (`UnifiedTask`), bằng chứng (`Evidence`) đến quyết định (`Decision`) và bài học (`LessonLearned`) đều nằm trong một Graph DB duy nhất.
- **Tích Hợp Sẵn Cụm Local AI (Qwen3 & Kev Decision API):** Trang bị cục bộ mô hình Vector Embedding (Qwen3-0.6B trên cổng 8082) và mô hình tính xác suất quyết định & tái xếp hạng (Kev-0.8B trên cổng 8081 qua giao thức SystemOne).
- **Fail-Fast & Truthful Health:** Khi xảy ra sự cố cơ sở dữ liệu hoặc phụ thuộc, hệ thống báo cáo chính xác trạng thái sức khỏe thực tế, lập tức dừng tiến trình nếu lỗi nghiêm trọng và tuyệt đối không bao giờ trả về dữ liệu ảo/mock.

2. Sơ Đồ Master Workflow Toàn Diện (End-to-End Operational Flowchart)

Sơ đồ luồng quyết định và luân chuyển dữ liệu toàn diện của hệ thống PTB: từ thu thập đa nguồn, kiểm soát lỗi Fail-Fast, lọc rác bằng Heuristic, trích xuất cấu trúc với LLM, thẩm định tương quan với Kev Decision API (:8081), lưu trữ vào Neo4j Single-Store đến phục vụ qua FastMCP (:8001) và OpenWebUI (:3000).



ACQUISITION & TRIAGE

Zero Manual Input & False-Positive Rejection

Lắng nghe HTTP responses ngầm từ Teams/Outlook Web, bảo lưu trạng thái bằng composite checkpoint tất định sha256. Bóc tách câu từ giao việc/cam kết bằng Heuristic trước khi đưa vào LLM (tiết kiệm 100% token cho tin chatter/bot). Các ứng viên mơ hồ (confidence 0.40–0.65) được đẩy sang Human Review Queue tại `/api/review`.

LOCAL AI & MEMORY ENGINE

Kev-0.8B Decision API & Neo4j Single-Store

Kev Decision Model API (:8081) chạy qua llama.cpp endpoint `/v1/systemone` tính xác suất quyết định (Choice Probabilities) để phát hiện task liên quan (anchor OPS-88) và tránh lỗi False Merge. Neo4j (:7687) là nguồn chân lý duy nhất lưu trữ UnifiedTask, Evidence, Decision; kích hoạt GraphMemorySyncWorker đồng bộ bất đồng bộ sang Graphiti Temporal Memory.

INTELLIGENCE & DELIVERED

Priority Engine & Bimodal Consumption

Priority Engine (0–100) tính điểm ưu tiên động dựa trên deadline decay, trọng số khách hàng và phát hiện cam kết bị quên (>3 ngày). Phân phối đa kênh qua OpenWebUI Board (:3000, 8 live views) và FastMCP Server (:8001, 10 read-only tools) cho AI Coding Agents (Cursor, Claude Code, Antigravity) lập trình theo đúng bối cảnh thực tế.

2.1 Bóc Tách Chi Tiết 8 Bước Vận Hành & 4 Điểm Rẽ Nhánh Quyết Định (Decision Gates)

Để giúp kỹ sư và quản trị hệ thống nắm vững cơ chế vận hành từ đầu đến cuối (End-to-End), bảng và diễn giải dưới đây chuẩn hóa toàn bộ các điều kiện rẽ nhánh và hành vi thực tế của mã nguồn:

TRẠM KIỂM SOÁT	THÀNH PHẦN MÃ NGUỒN	ĐIỀU KIỆN ĐÁNH GIÁ	NHÁNH DƯƠNG (TRUE / PASSED)	NHÁNH ÂM (FALSE / DIVERTED)
Gate 1: Health Guard	`supervisor.py` `api.py`	Phiên đăng nhập Teams/Outlook còn hạn và Neo4j :7687 sẵn sàng?	**Tiếp tục pipeline:** Mở Playwright Interceptor hoặc Polling Adapter.	**Fail-Fast Halt:** Phát xạ `PTB-STORAGE-001` hoặc `PTB-L1-001`, dừng tiến trình (exit != 0). Không bao giờ trả mock data.
Gate 2: Heuristic Candidate	`normalizer.py` `extractor.py`	Tin nhắn có chứa từ khóa cam kết hành động ("sẽ làm", "deadline", "nhờ")?	**Chuyển sang L2:** Đưa nội dung vào hàng đợi gọi LLM Structured Extraction.	**Drop Chatter (0 Token):** Đánh dấu `status: PROCESSED` ngay lập tức, tiết kiệm 100% token LLM cho tin chào hỏi và bot alert.
Gate 3: Attribution Validator	`validator.py` `schemas.py`	Điểm tin cậy trích xuất người cam kết & bằng chứng: `Confidence ≥ 0.65`?	**High Confidence:** Chuyển sang trạm thẩm định tương quan và hợp nhất nhiệm vụ.	**Human-in-the-Loop Queue:** Điểm lấp lửng (0.40–0.65) được đẩy sang `/api/review` để người dùng xác nhận bằng tay, tránh hallucination.
Gate 4: Kev-0.8B Decision API	`ai_service.py` `llama.cpp (:8081)`	Xác suất liên kết với Task/Anchor hiện có (`/v1/systemone` Choice Probabilities)?	**Correlation Merge:** Gộp vào `UnifiedTask` có sẵn (ví dụ anchor `OPS-88`) và bổ sung quan hệ `(:Evidence)` mới.	**New Task Creation:** Khởi tạo `UnifiedTask` độc lập mới trong Neo4j với mã nhận diện duy nhất. Tránh lỗi False Merge.

Vị Trí Cốt Lõi Của Kev Decision Model API (:8081): Nhiều hệ thống quản lý công việc truyền thống thường gặp lỗi "False Merge" (gộp nhầm 2 việc khác nhau vào cùng 1 ticket) hoặc "Duplicate Explosion" (mỗi tin nhắn tạo 1 ticket mới). PTB giải quyết triệt để nhờ `Kev-0.8B` chạy tại cổng 8081: mô hình tính toán Choice Probabilities để ra quyết định gộp dựa trên ngữ cảnh thực tế của cuộc hội thoại, đồng thời re-rank các Quyết Định Kiến Trúc (ADR) và Bài Học Kinh Nghiệm (Lessons) liên quan nhất.

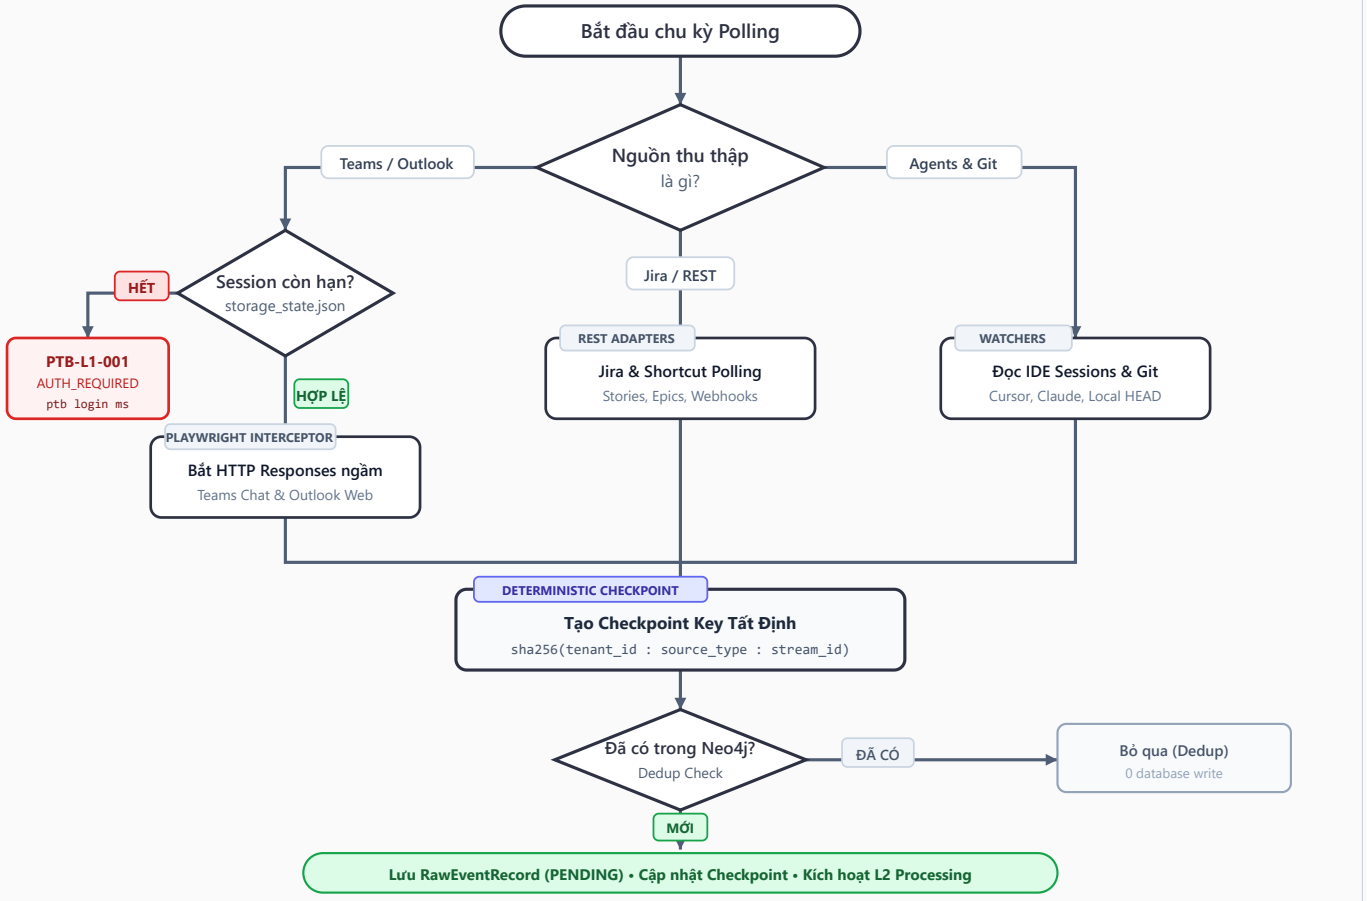
Điểm Tựa Neo4j Single-Store & Bimodal Consumption: Sau khi vượt qua 4 cổng quyết định, dữ liệu được ghi bền vững vào Neo4j (:7687). `PriorityEngine` tự động gán điểm ưu tiên (0–100) và phát hiện cam kết bị lãng quên (> 3 ngày). Dữ liệu này được tiêu thụ đồng thời qua 2 kênh: **OpenWebUI (:3000)** cho con người theo dõi trực quan và **FastMCP Server (:8001)** cho các AI Coding Agents (Cursor, Claude Code, Antigravity) tự động lấy bối cảnh khi lập trình.

3. Các Pipeline Nghiệp Vụ Chuyên Sâu

3.1 Workflow Layer 1: Thu Thập Đa Nguồn & Checkpoint Tất Định

Lắng nghe dữ liệu thô từ mọi nguồn ngoại vi. Điểm mấu chốt là **tính tất định của con trỏ IngestionCheckpoint**: định danh băm `sha256(tenant_id:source_type:stream_id)` độc lập hoàn toàn giữa các tenant Microsoft và nguồn cục bộ, ngăn ngừa tuyệt đối lỗi tải trùng dữ liệu (backfill leak).

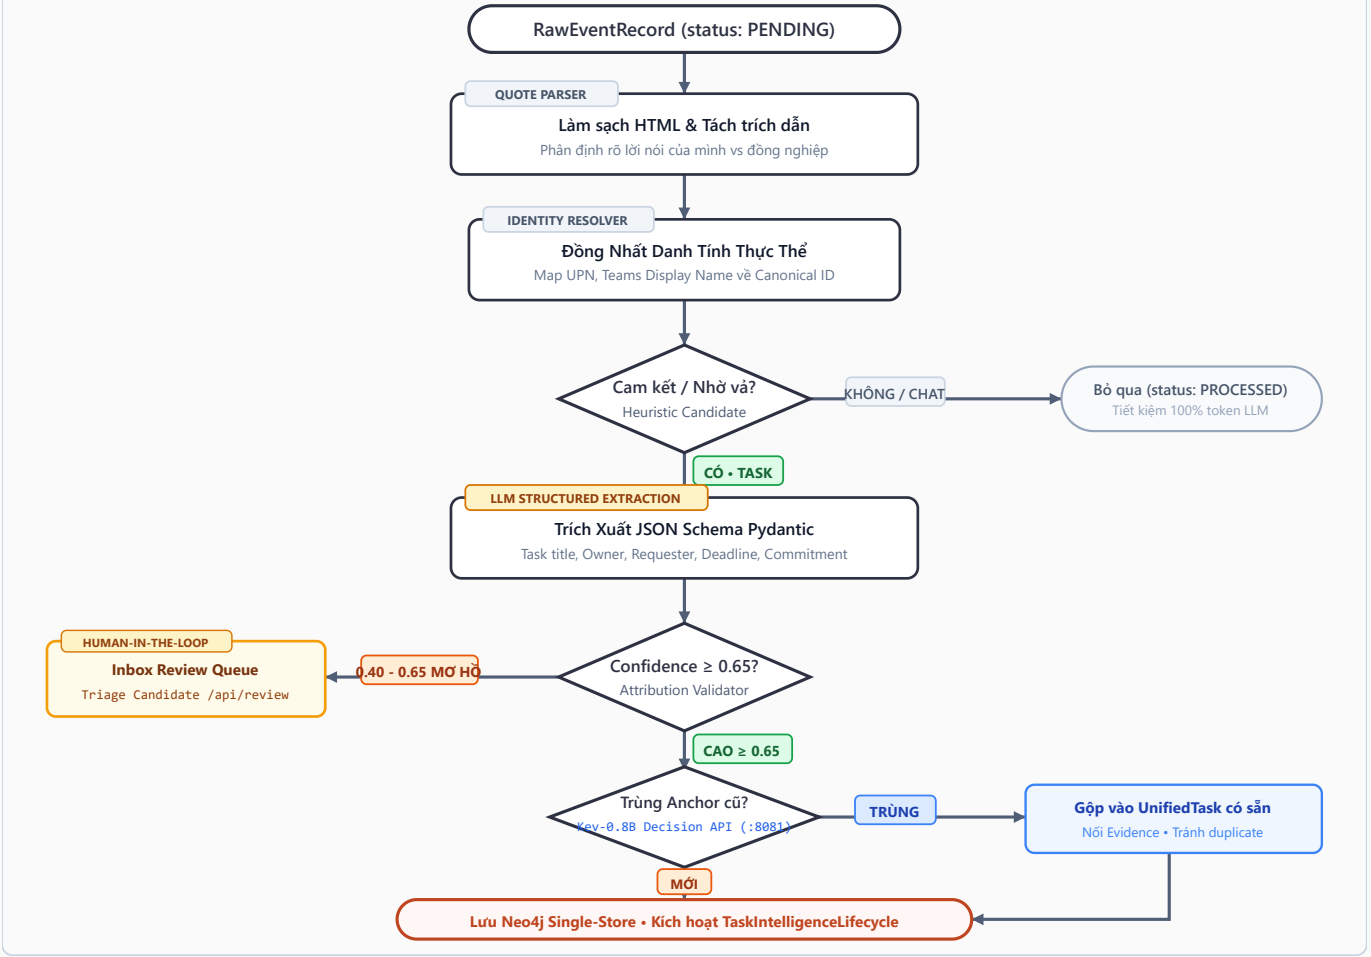
WORKFLOW A: INGESTION & CHECKPOINT PIPELINE



3.2 Workflow Layer 2: Tiền Xử Lý, Trích Xuất LLM & Hợp Nhất Tương Quan

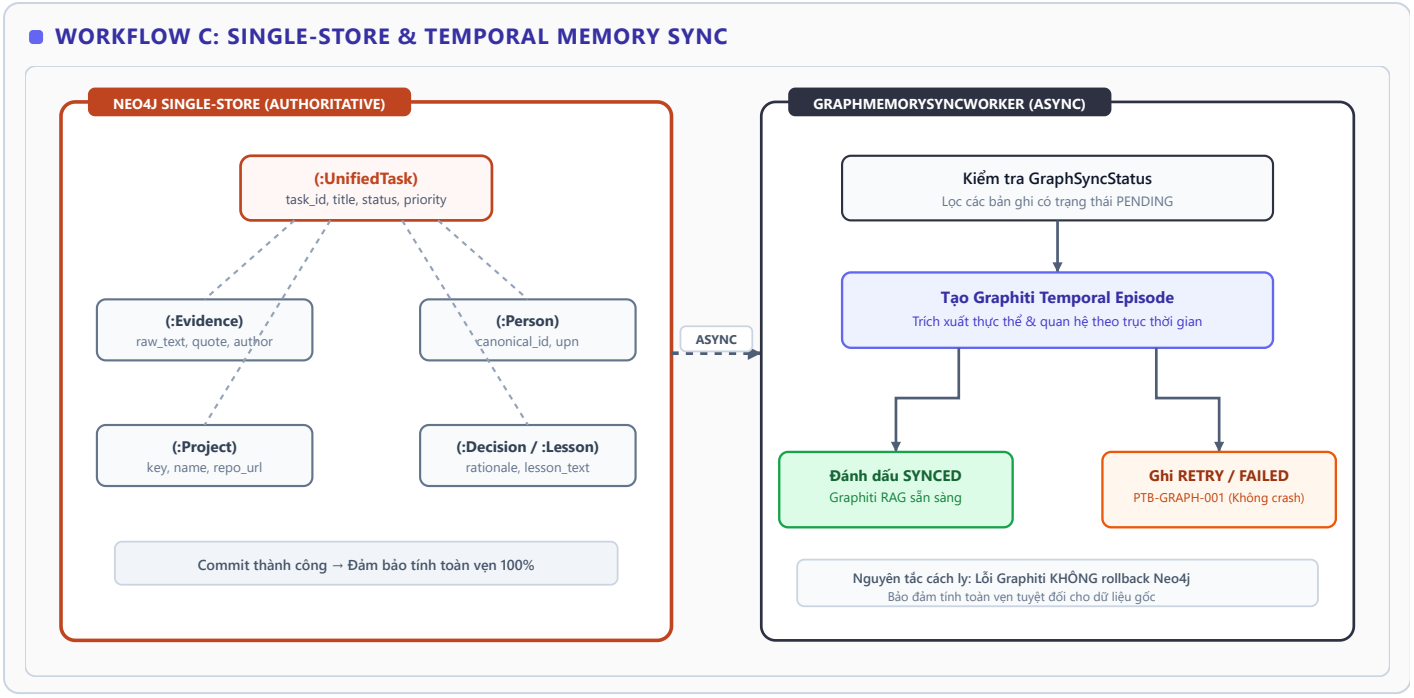
Giải quyết rủi ro lớn nhất: **Sai quy kết (Attribution Risk)**. Quote Parser bóc tách chính xác phần nào là lời nói của mình và phần nào là của đồng nghiệp trước khi đưa vào LLM.

WORKFLOW B: PROCESSING & CORRELATION PIPELINE



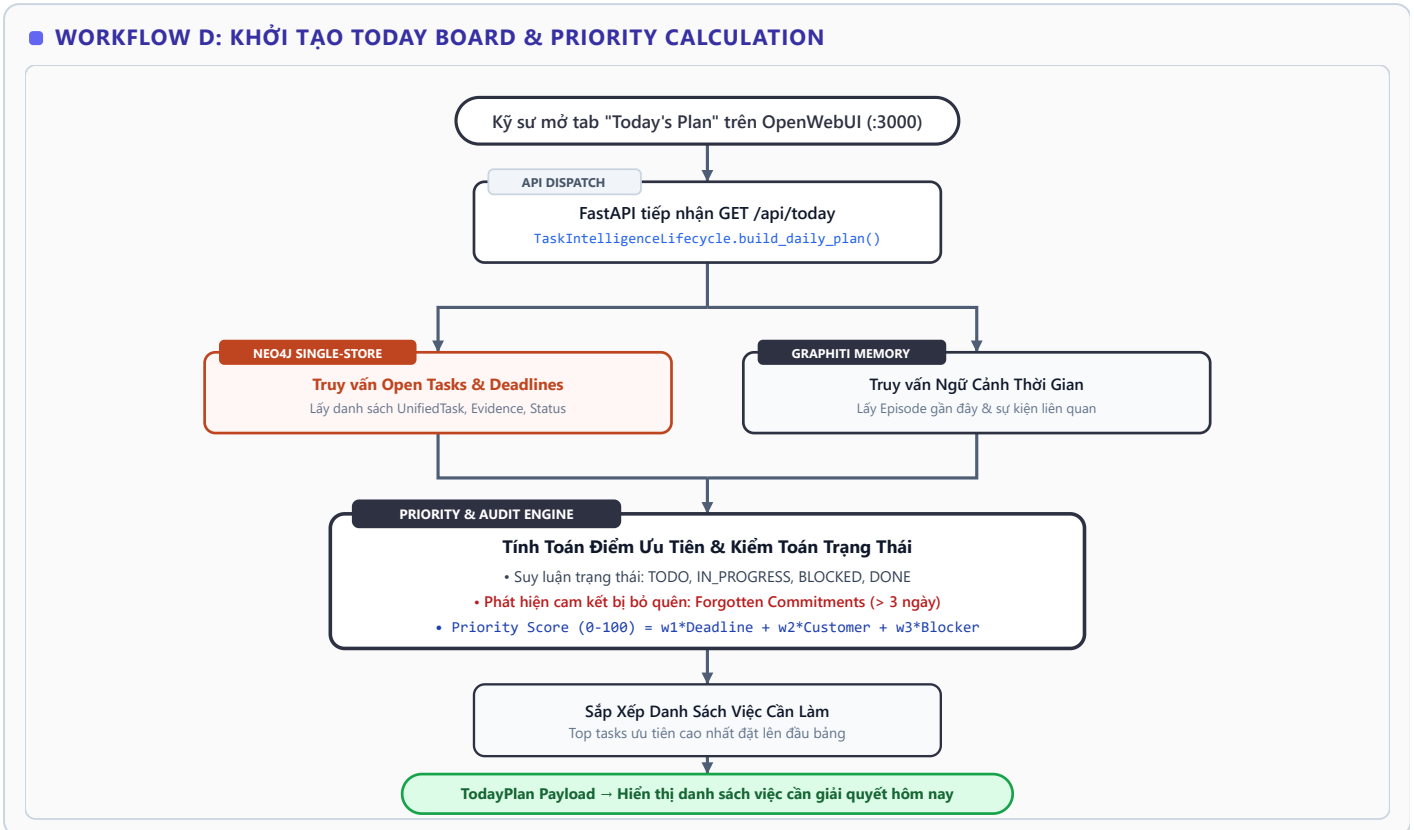
3.3 Workflow Layer 3: Đồ Thị Tri Thức Neo4j & Bộ Nhớ Thời Gian Graphiti

Toàn bộ dữ liệu nghiệp vụ chuẩn hóa vào **Neo4j Single-Store**. Phân hệ `GraphMemorySyncWorker` đảm nhận việc đồng bộ các sự kiện thành Episode trong **Graphiti Temporal GraphRAG** hoàn toàn bất đồng bộ (Async) mà không bao giờ chặn hay rollback transaction chính.



3.4 Workflow Layer 4: Động Cơ Trí Tuệ & Sinh Kế Hoạch Hôm Nay

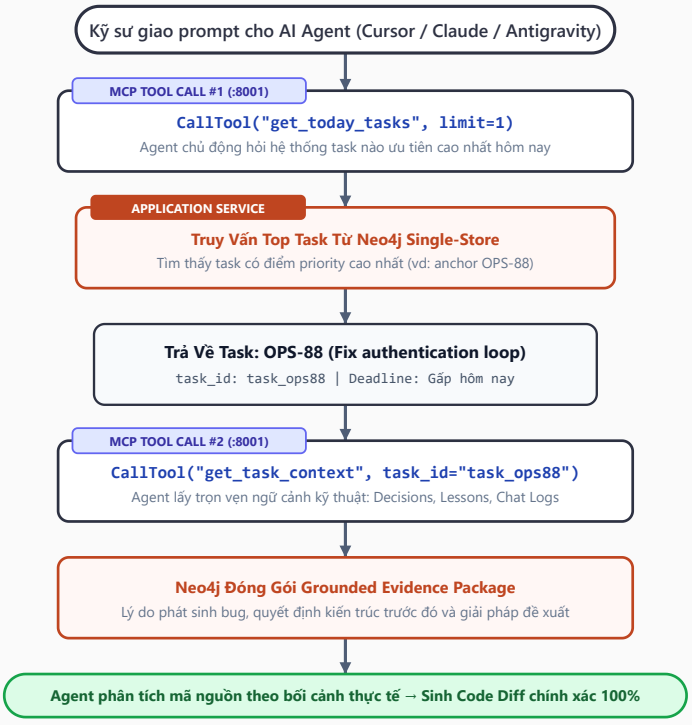
Động cơ `PriorityEngine` tự động tính toán điểm số từ **0 đến 100** dựa trên công thức suy giảm deadline (Deadline Decay), trọng số khách hàng (Customer Weight) và trạng thái bị chặn (Blocker Urgency).



3.5 Workflow Layer 5: Tích Hợp Coding Agents Qua FastMCP Server

Máy chủ **FastMCP Server (Port 8001 / SSE)** cung cấp đúng **10 công cụ truy vấn chỉ đọc (Read-Only)**. Các Coding Agent (Cursor, Claude Code, Antigravity) có thể chủ động tra cứu bối cảnh công việc và bằng chứng mà không làm thay đổi dữ liệu gốc.

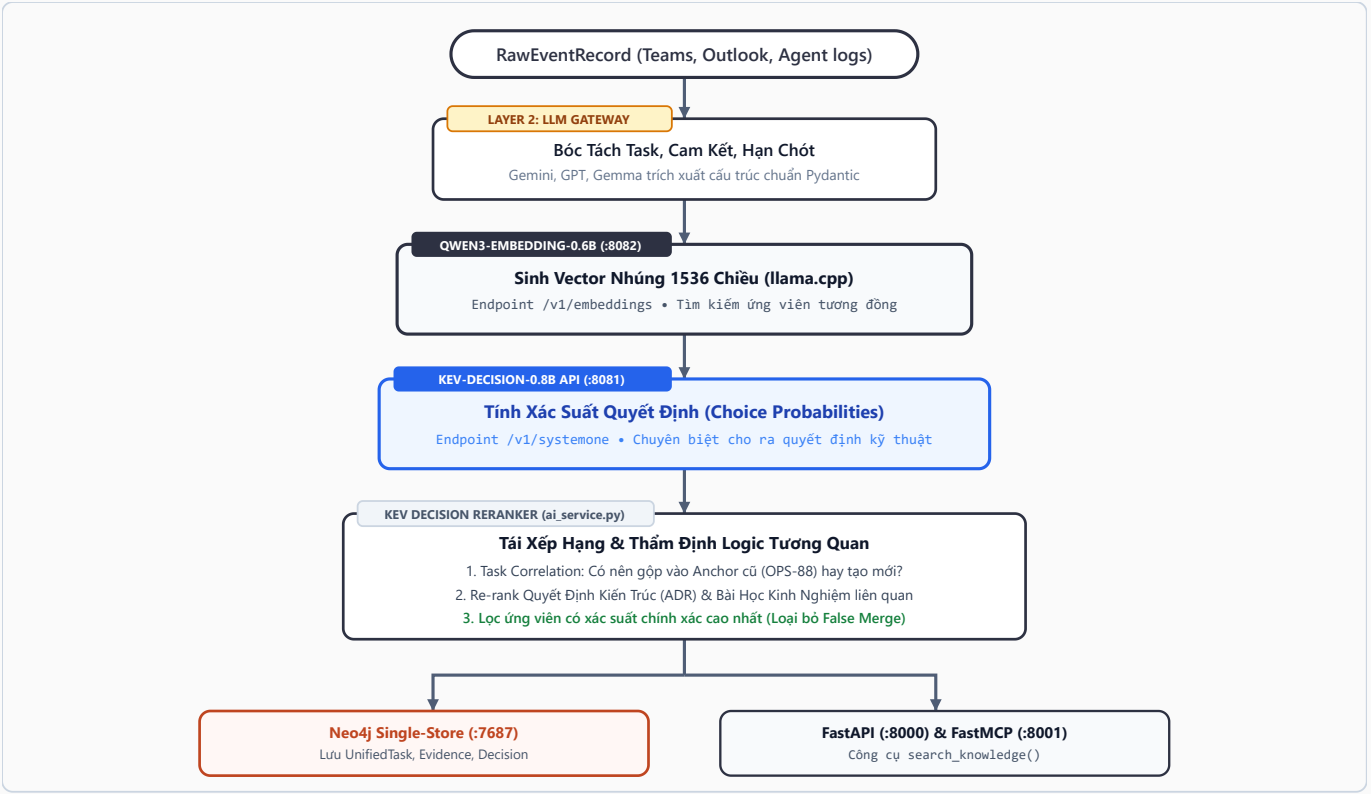
WORKFLOW E: AI CODING AGENT TƯƠNG TÁC QUA FASTMCP



3.6 Cụm Local AI: Qwen3 Embedding (:8082) & Kev Decision Model API (:8081)

Vai trò của Kev Decision API: Mô hình `Kev-0.8B-Q8_0` (812 MB) chạy qua `llama.cpp` tại cổng **8081** đóng vai trò là một **Decision Model API** chuyên biệt. Thay vì chỉ sinh text tự do, Kev sử dụng giao thức `/v1/systemone` để tính toán xác suất lựa chọn quyết định (Choice Probabilities), phục vụ: (1) Thẩm định tương quan và hợp nhất nhiệm vụ (Task Correlation); (2) Tái xếp hạng (Re-ranking) kết quả tìm kiếm ngữ nghĩa; (3) Cung cấp tri thức quyết định kiến trúc (ADR Decisions) và bài học kinh nghiệm (Lessons) cho các công cụ OpenWebUI (`search_knowledge` trong `ptb_tools.py`).

WORKFLOW F: AI DECISION & RERANKING PIPELINE VỚI KEV VÀ QWEN3

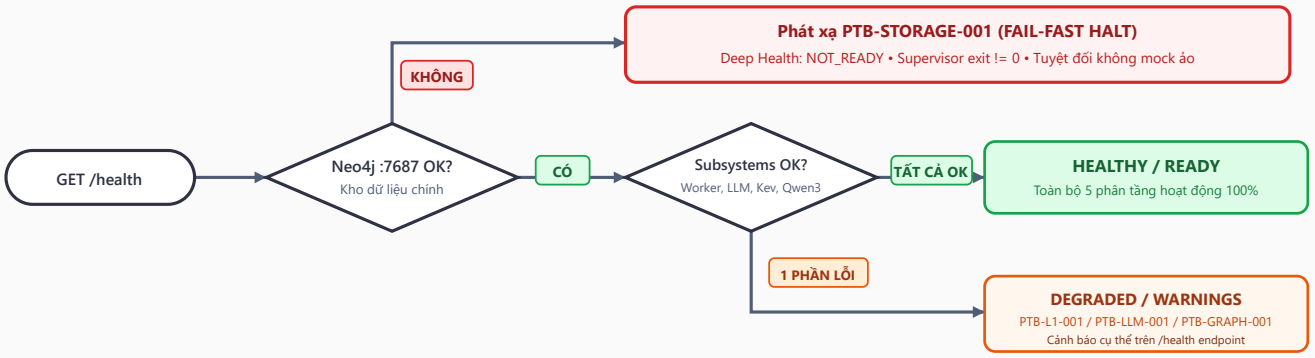


Trong mã nguồn, class `KevDecisionReranker` tại `packages/ai_service.py` đọc biến môi trường `DECISION_BASE_URL` (mặc định `http://127.0.0.1:8081/v1`). Khi người dùng tìm kiếm tri thức qua OpenWebUI (ví dụ hàm `search_knowledge()` trong `ptb_tools.py`), KEV tự động xếp hạng các Quyết định Kiến trúc (ADR) và Bài học Kinh nghiệm (Lessons) phù hợp nhất với ngữ cảnh hiện tại.

3.7 Cơ Chế Fail-Fast, Truthful Health & 10 Mã Lỗi Chuẩn Hóa

Mọi sự cố bất thường đều được ghi nhận qua hàm `log_bug()` với cấu trúc trường nghiêm ngặt, gắn với 10 mã lỗi chuẩn hóa để phục vụ giám sát và tự phục hồi:

WORKFLOW G: CƠ CHẾ LAN TRUYỀN TRẠNG THÁI SỨC KHỎE & MÃ LỖI



MÃ LỖI	PHÂN HỆ	MÔ TẢ SỰ CỐ	HÀNH VI HỆ THỐNG (FAIL-FAST)
`PTB-STORAGE-001`	`neo4j`	Kho dữ liệu chính Neo4j không khả dụng	Fail-fast: Supervisor chuyển NOT_READY và dừng tiến trình.
`PTB-CKPT-001`	`checkpoint`	Không nhất quán đọc/ghi con trỏ đồng bộ	Bảo vệ tính toàn vẹn luồng, không silent fallback.
`PTB-L1-001`	`playwright`	Phiên đăng nhập Teams/Outlook hết hạn	Chuyển AUTH_REQUIRED, yêu cầu `ptb login microsoft`.
`PTB-L1-002`	`adapter`	Lỗi thu thập mạng hoặc adapter polling	Retry độc lập với thuật toán exponential backoff.
`PTB-L2-001`	`processing`	Lỗi pipeline xử lý bóc tách sự kiện thô	Tăng attempt_count, chuyển RETRY hoặc FAILED.
`PTB-LLM-001`	`llm`	Lỗi kết nối nhà cung cấp LLM hoặc timeout	Đánh dấu subsystem LLM DEGRADED, không tạo fake data.
`PTB-GRAPH-001`	`graph_memory`	Lỗi kết nối hoặc đồng bộ Graphiti Memory	Bảo toàn Neo4j, chuyển GraphSyncStatus sang RETRY.
`PTB-APP-001`	`application`	Thành phần phụ thuộc trọng yếu của AppService lỗi	Endpoint `GET /health` trả về `not_ready`.
`PTB-MCP-001`	`mcp`	Máy chủ FastMCP hoặc kết nối app service lỗi	Endpoint `:8001/health` báo cáo không sẵn sàng.
`PTB-OWUI-001`	`openwebui`	Giao diện OpenWebUI không gọi được REST API	Hiển thị thông báo rõ ràng: APPLICATION SERVICE OFFLINE.

4. Bản Đồ Hạ Tầng, Cổng Dịch Vụ & Bộ Kiểm Chuẩn Benchmark

4.1 Bản Đồ Cổng Dịch Vụ Mạng (Port Map)

CỔNG (PORT)	DỊCH VỤ VẬN HÀNH	CÔNG NGHỆ SỬ DỤNG	VAI TRÒ TRONG HỆ THỐNG
`:3000`	OpenWebUI Board	Docker (ghcr.io/open-webui)	Giao diện web cá nhân hiển thị 8 Views live-only (Today, Tasks, Review, Forgotten...).
`:7474 / :7687`	Neo4j Single-Store	Neo4j Community 5.26 + APOC	Cơ sở dữ liệu đồ thị nguồn chân lý duy nhất (RawEvents, Tasks, Checkpoints, Evidences).
`:8000`	Application Service REST	Python FastAPI	Cung cấp 20 REST API endpoints phục vụ logic nghiệp vụ cho OpenWebUI và Portal.
`:8001`	FastMCP Server	Python FastMCP (SSE Transport)	Cung cấp 10 công cụ truy vấn chỉ đọc cho Cursor, Claude Code, Antigravity, Cline.
`:8081`	Local Kev Decision API	llama.cpp + Kev-0.8B-Q8_0	Mô hình Decision & Choice Probabilities API (/v1/systemone) phục vụ tái xếp hạng.
`:8082`	Local Qwen3 Embedding	llama.cpp + Qwen3-Embedding-0.6B	Mô hình Vector Embedding cục bộ chuẩn OpenAI `/v1/embeddings`.

4.2 Bộ Đánh Giá Chất Lượng Small Benchmark SB-v0.1

Dự án tích hợp bộ Benchmark tự động hóa chuẩn hóa kiểm định 100% không phụ thuộc mock ảo:

- **Tập Dữ Liệu Chuẩn:** 12 RawEvents thực tế (4 Teams + 2 Outlook + 3 Antigravity + 3 Cline) được gán nhãn Oracle chính xác 100%.
- **4 Failure Probes:** Kiểm thử lỗi LLM timeout (L2), khử trùng lặp RawEvent (L3), cơ chế Fail-fast của Neo4j (Runtime) và xử lý phiên hết hạn Auth Expired (L1).
- **Replay Engine:** Chụp ảnh `StateSnapshot` và phát lại sự kiện tuần tự, chứng minh tính bất biến và khử trùng lặp tuyệt đối (0 duplicate task).
- **Kết quả nghiệm thu:** Đạt 12/12 Cases PASS, Precision = 100%, Recall = 100%, F1 = 100%, 0 nhãn mâu thuẫn.

> **Tổng kết kiến trúc:** Personal Task Board (PTB) v1.3 là một kiến trúc Local-First hoàn chỉnh, kết hợp sức mạnh của đồ thị tri thức Neo4j, trí tuệ LLM bóc tách có cấu trúc, cụm Local AI Inference (Qwen3 & Kev Decision API) và giao thức FastMCP hiện đại để đem lại sự minh bạch toàn diện cho công việc hàng ngày của kỹ sư phần mềm.